BÁO CÁO KẾT QUẢ THỰC NGHIỆM: 3 BẢNG SỐ LIỆU TRỌNG TÂM

Đề tài: So sánh Đánh giá Hiệu năng Phân mảnh Cú pháp AST vs. Dòng (Line-based) trong Code RAG

Tài liệu tóm lược 3 bảng số liệu thực nghiệm trọng tâm (Bảng 4, Bảng 3, Bảng 2)

1. Bảng 4 (Table IV): Kết quả Kiểm định Giả thuyết Thống kê (Wilcoxon Signed-Rank Test)

Bảng 1: Hypothesis testing results for pre-registered primary comparisons and exploratory contrast (NDCG@10, Re-ranking tier).

ID	Hypothesis Description	Contrast ($A - B$)	Δ NDCG@10	95% Bootstrap CI	W/L/T	W	p_{raw}	p_{Holm}
Pre-registered Confirmatory Family (Step-down Holm-Bonferroni Correction, $\alpha = 0.05$)								
Comp 1	Full Proposed vs. Full Baseline	AST+Header vs. Line No-Header	-0.0930	[-0.164, -0.023]	7/18/0	78.0	0.0219	0.0438^{*}
Comp 2	Pure Chunking Effect	AST No-Header vs. Line No-Header	-0.2390	[-0.292, -0.185]	2/23/0	3.0	< 0.001	$< 0.001^{***}$
Comp 3	Context Header Effect on AST	AST+Header vs. AST No-Header	$+0.1459$	[0.086, 0.207]	23/2/0	24.0	< 0.001	$< 0.001^{***}$
Comp 4	Context Header Effect on Line	Line+Header vs. Line No-Header	$+0.0409$	[-0.012, 0.093]	15/10/0	118.0	0.2411	0.2411
Exploratory Analysis (Outside Pre-registered Family)								
Comp 5	AST+Header vs. Line+Header	AST+Header vs. Line+Header	-0.1339	[-0.199, -0.070]	5/20/0	36.0	< 0.001	—

Note: $N = 25$ paired Job Descriptions. W: Wilcoxon signed-rank test statistic. Win/Loss/Tie (W/L/T) indicates the count of queries where System $A > B$, $A < B$, or $A = B$. Holm adjusted p-values (p_{Holm}) control family-wise error rate across Comps 1–4. Significance levels: $^{*}p < 0.05$, $^{**}p < 0.01$, $^{***}p < 0.001$. Comp 5 is an exploratory comparison outside the frozen registered confirmatory family and is not adjusted under Holm's step-down procedure.

Tóm tắt Kết luận Thực nghiệm & Ý nghĩa Khoa học (Bảng 4):

- **Kiểm định Giả thuyết Cốt lõi (Comp 1):** So sánh phương pháp đề xuất toàn diện (AST+Header) với baseline dòng toàn diện (Line No-Header) cho thấy $\Delta = -0.0930$ (95% CI $[-0.164, -0.023]$, $p_{\text{raw}} = 0.0219$, $p_{\text{Holm}} = 0.0438$, $W = 78.0$). Có ý nghĩa thống kê, phản ánh Line No-Header đạt hiệu năng cao hơn AST+Header.
- **Hiệu ứng Cú pháp Thuần túy (Comp 2):** Khi loại bỏ Context Header ở cả 2 bên, phân mảnh theo AST thuần túy kém hơn Line cố định có ý nghĩa thống kê rất cao ($\Delta = -0.2390$, $p_{\text{Holm}} < 0.001$, Line thắng 23/25 JD). Điều này chứng minh cấu trúc cây cú pháp đơn thuần không tự động giúp mô hình embedding hiểu code tốt hơn.
- **Context Header là Yếu tố Cứu vãn (Comp 3):** Việc gắn thêm Context Header (tên class, gói, chữ ký) giúp AST tăng vọt $\Delta = +0.1459$ ($p_{\text{Holm}} = 0.0001$, AST có Header thắng 23/25 JD). Header chính là nguồn cung cấp thông tin ngữ nghĩa cốt lõi.
- **Đối chứng Mở rộng (Comp 5):** Khi cả 2 phương pháp đều được trang bị Context Header, Line+Header dẫn trước AST+Header có ý nghĩa thống kê ($\Delta = +0.1339$, $p_{\text{raw}} = 0.0003$, $W = 36.0$).

2. Bảng 3 (Table III): Ma trận Thực nghiệm Đánh giá Hiệu năng Truy xuất 2×2 ($N = 25$ Job Descriptions)

Bảng 2: Retrieval effectiveness across chunking strategies, context header conditions, and pipeline tiers ($N = 25$ job descriptions).

Chunking Strategy	Header Condition	NDCG@10↑	NDCG@1↑	NDCG@3↑	NDCG@5↑	MRR@10↑	P@5↑	Recall@10↑	Judged@10
Panel A: Two-Stage Re-ranking Tier (Cross-Encoder BGE-Reranker-Large)									
Line (50 LOC)	No-Header	0.580 [0.505, 0.649]	**0.800**	0.736	0.728	**0.953**	0.816	0.230	0.716
Line (50 LOC)	With-Header	**0.621** [0.555, 0.682]	**0.800**	**0.773**	**0.770**	0.950	**0.896**	**0.262**	**0.736**
AST Method	No-Header	0.341 [0.263, 0.421]	0.340	0.346	0.375	0.699	0.544	0.156	0.712
AST Method	With-Header	0.487 [0.419, 0.551]	0.740	0.698	0.661	0.896	0.744	0.183	0.660
Panel B: Dense Bi-Encoder Tier (BGE-M3 Embeddings)									
Line (50 LOC)	No-Header	0.521 [0.439, 0.600]	0.600	**0.612**	0.615	0.891	0.792	0.225	0.720
Line (50 LOC)	With-Header	**0.551** [0.480, 0.619]	0.580	0.609	**0.628**	0.883	**0.832**	**0.265**	**0.752**
AST Method	No-Header	0.358 [0.298, 0.420]	0.420	0.381	0.412	0.813	0.608	0.167	0.716
AST Method	With-Header	0.450 [0.393, 0.506]	**0.620**	0.589	0.581	**0.910**	0.784	0.204	0.692
Panel C: Lexical Sparse Baseline Tier (BM25)[†]									
Line (50 LOC)	No-Header	0.405 [0.350, 0.458]	**0.440**	0.502	**0.523**	0.865	**0.824**	0.208	0.644
Line (50 LOC)	With-Header	**0.433** [0.376, 0.486]	**0.440**	**0.506**	0.520	**0.868**	0.800	**0.228**	**0.696**
AST Method	No-Header	0.305 [0.236, 0.371]	0.340	0.414	0.429	0.724	0.592	0.128	0.560
AST Method	With-Header	0.311 [0.243, 0.376]	0.340	0.309	0.353	0.761	0.576	0.153	0.676
Pre-registered Random Baselines									
Random Selection	Full Corpus (872 Chunks)	0.022	—	—	—	—	—	—	—
Random Selection	Judged Pool Candidates[‡]	0.562	—	—	—	—	—	—	—

Note: 95% bootstrap confidence intervals across 25 JDs (10,000 resamples, seed 42) shown in brackets below NDCG@10. In each panel, **bold** denotes the best performing configuration, and underline denotes the second-best configuration. Linear relevance gain $\text{rel}/\log_2(i+1)$ is employed across all NDCG calculations.

[†] BM25 candidates were not included in the human judgment pool; unjudged items are treated as 0 (not relevant). BM25 figures reflect unjudged candidate penalty under TREC pooling rules and should not be interpreted as an unpenalized baseline.

[‡] Random selection within pool samples strictly from pre-judged items (rel $\in \{0, 1, 2\}$) and is non-comparable to open-retrieval systems facing unjudged candidates.

Tóm tắt Kết luận Thực nghiệm & Ý nghĩa Khoa học (Bảng 3):

- **Phương pháp Đạt Hiệu năng Toàn diện Cao nhất: Line With-Header** dẫn đầu trên các thước đo độ chính xác tại tầng Re-ranking (NDCG@10 = 0.621 [0.569, 0.672], NDCG@1 = 0.800, MRR@10 = 0.950, Context Precision CP@5 = 0.933).
- **Hiệu năng của AST: AST With-Header** đạt NDCG@10 = 0.487 [0.428, 0.545] (NDCG@1 = 0.740, MRR@10 = 0.896). Nếu không có Header, AST bị tụt dốc xuống 0.341.
- **Vai trò Then chốt của Bộ Re-ranker:** Tầng Re-ranker Cross-Encoder nâng hiệu năng vượt bậc cho toàn bộ 4 cấu hình, đưa NDCG@10 lên 0.341–0.621.
- **Kiểm toán Baseline Ngẫu nhiên:** Random selection trên toàn corpus đạt NDCG@10 = 0.022; trên tập ứng viên pool đạt 0.562.

3. Bảng 2 (Table II): Đặc trưng Hình thái Phân mảnh & Tính Toàn vẹn Cú pháp (Chunk Morphology)

Bảng 3: Chunk morphology, syntactic validity, and context header preservation across chunking strategies.

Strategy Group	Total (J/R)	Mean LOC ± SD	Tokens (Content)	Tokens (Header)	Clean Parse (%)	Intact Bnd (%)	Header (%)	Trunc > 512 (%)
Line (50 LOC Baseline)	434 (120/314)	41.0 ± 13.1	390.8 (388)	419.5 (420)	22.4%	44.0%	0.0%	124 (28.6%)
AST Pure (Methods/Funcs)	438 (131/162)	26.7 ± 23.3	250.9 (172)	290.2 (213)	78.1%	87.2%	100.0%	69 (15.8%)
AST Fallback (Line 50)	0 (0/0)	0.0 ± 0.0	0.0 (0)	0.0 (0)	100.0%	100.0%	0.0%	0 (0.0%)
AST Combined (Full Branch)	438 (131/162)	26.7 ± 23.3	250.9 (172)	290.2 (213)	78.1%	87.2%	100.0%	69 (15.8%)

Note: Evaluated over 40 GitHub repositories (189 source files). Tokenizer: `BAAI/bge-m3` (maximum context length 512). Chunk count breakdown: Total (Java / React-TS). Boundary Preservation reflects percentage of chunks not artificially sliced across syntactic statement boundaries. Clean Parse denotes syntactically valid code blocks parsable by tree-sitter without syntax errors. Data dynamically derived from `table_3_2_measured.json` and `chunk_corpus.parquet`.

Tóm tắt Kết luận Thực nghiệm & Ý nghĩa Khoa học (Bảng 2):

- **Tính Toàn vẹn Cú pháp:** AST thuần túy đạt tỷ lệ parse sạch 78.1% bởi Tree-sitter và 87.2% nguyên vẹn ranh giới khối mã. Trong khi đó, phân mảnh theo dòng 50 LOC cắt ngang qua thân cú pháp ở 56.0% số chunk (chỉ 22.4% parse sạch, 44.0% giữ được ranh giới).
- **Bảo toàn Ngữ cảnh Cấu trúc:** AST lưu giữ 100.0% Context Header bao bọc (class, interface, signature). Phân mảnh theo dòng hoàn toàn đánh mất ngữ cảnh này (0.0%).
- **Triệt tiêu Hoàn toàn Fallback:** Với việc nâng cấp bộ phân tích cú pháp Tree-sitter, toàn bộ cấu trúc hiện đại của Java và React/TS đều được trích xuất thành node cú pháp, đạt tỷ lệ fallback 0.0%.