BÁO CÁO KẾT QUẢ THỰC NGHIỆM: 3 BẢNG SỐ LIỆU TRỌNG TÂM

Đề tài: So sánh Đánh giá Hiệu năng Phân mảnh Cú pháp AST vs. Dòng (Line-based) trong Code RAG

Tài liệu tóm lược 3 bảng số liệu thực nghiệm trọng tâm (Bảng 4, Bảng 3, Bảng 2)

1. Bảng 4 (Table IV): Kết quả Kiểm định Giả thuyết Thống kê (Wilcoxon Signed-Rank Test)

Bảng 1: Hypothesis testing results for pre-registered primary comparisons and exploratory contrast (NDCG@10, Re-ranking tier).

ID	Hypothesis Description	Contrast ($A - B$)	Δ NDCG@10	95% Bootstrap CI	W/L/T	W	p_{raw}	p_{Holm}
Pre-registered Confirmatory Family (Step-down Holm-Bonferroni Correction, $\alpha = 0.05$)								
Comp 1	Full Proposed vs. Full Baseline	AST+Header vs. Line No-Header	-0.0138	[-0.088, 0.058]	12/13/0	155.0	0.8532	0.8532
Comp 2	Pure Chunking Effect	AST No-Header vs. Line No-Header	-0.1258	[-0.180, -0.076]	5/20/0	22.0	< 0.001	$< 0.001^{***}$
Comp 3	Context Header Effect on AST	AST+Header vs. AST No-Header	$+0.1120$	[0.056, 0.166]	19/6/0	46.0	0.0010	0.0031^{**}
Comp 4	Context Header Effect on Line	Line+Header vs. Line No-Header	$+0.0291$	[-0.017, 0.078]	15/10/0	128.0	0.3666	0.7332
Exploratory Analysis (Outside Pre-registered Family)								
Comp 5	AST+Header vs. Line+Header	AST+Header vs. Line+Header	-0.0428	[-0.106, 0.021]	6/18/1	97.0	0.1355	—

Note: $N = 25$ paired Job Descriptions. W: Wilcoxon signed-rank test statistic. Win/Loss/Tie (W/L/T) indicates the count of queries where System $A > B$, $A < B$, or $A = B$. Holm adjusted p-values (p_{Holm}) control family-wise error rate across Comps 1–4. Significance levels: $^{*}p < 0.05$, $^{**}p < 0.01$, $^{***}p < 0.001$. Comp 5 is an exploratory comparison outside the frozen registered confirmatory family and is not adjusted under Holm's step-down procedure.

Tóm tắt Kết luận Thực nghiệm & Ý nghĩa Khoa học (Bảng 4):

- **Kiểm định Giả thuyết Cốt lõi (Comp 1):** So sánh phương pháp đề xuất toàn diện (AST+Header) với baseline dòng toàn diện (Line No-Header) cho thấy $\Delta = -0.0138$ (95% CI $[-0.088, 0.058]$, $p_{\text{raw}} = 0.8532$, $p_{\text{Holm}} = 0.8532$, $W = 155.0$). **Giả thuyết đặt ra ban đầu rằng AST vượt trội hơn Line không đạt ý nghĩa thống kê** (không bác bỏ được H_0).
- **Hiệu ứng Cú pháp Thuần túy (Comp 2):** Khi loại bỏ Context Header ở cả 2 bên, phân mảnh theo AST thuần túy kém hơn Line cố định có ý nghĩa thống kê rất cao ($\Delta = -0.1258$, $p_{\text{Holm}} < 0.001$, Line thắng 20/25 JD). Điều này chứng minh cấu trúc cây cú pháp đơn thuần không tự động giúp mô hình embedding hiểu code tốt hơn.
- **Context Header là Yếu tố Cứu vãn (Comp 3):** Việc gắn thêm Context Header (tên class, gói, chữ ký) giúp AST tăng vọt $\Delta = +0.1120$ ($p_{\text{Holm}} = 0.0031$, AST có Header thắng 19/25 JD). Header chính là nguồn cung cấp thông tin ngữ nghĩa cốt lõi.
- **Đối chứng Mở rộng (Comp 5):** Khi cả 2 phương pháp đều được trang bị Context Header, Line+Header vẫn đạt điểm cao hơn AST+Header ($\Delta = +0.0428$, $p_{\text{raw}} = 0.1355$, $W = 97.0$).

2. Bảng 3 (Table III): Ma trận Thực nghiệm Đánh giá Hiệu năng Truy xuất 2×2 ($N = 25$ Job Descriptions)

Bảng 2: Retrieval effectiveness across chunking strategies, context header conditions, and pipeline tiers ($N = 25$ job descriptions).

Chunking Strategy	Header Condition	NDCG@10↑	NDCG@1↑	NDCG@3↑	NDCG@5↑	MRR@10↑	P@5↑	Recall@10↑	Judged@10
Panel A: Two-Stage Re-ranking Tier (Cross-Encoder BGE-Reranker-Large)									
Line (50 LOC)	No-Header	0.470 [0.414, 0.524]	0.740	0.703	0.587	0.933	0.656	0.246	**0.564**
Line (50 LOC)	With-Header	**0.499** [0.450, 0.543]	**0.800**	**0.736**	**0.630**	**0.980**	**0.704**	**0.262**	0.552
AST Method	No-Header	0.345 [0.299, 0.390]	0.460	0.477	0.399	0.846	0.560	0.220	0.536
AST Method	With-Header	0.457 [0.405, 0.509]	0.720	0.675	0.564	0.940	0.648	0.253	0.564
Panel B: Dense Bi-Encoder Tier (BGE-M3 Embeddings)									
Line (50 LOC)	No-Header	0.446 [0.377, 0.511]	0.600	0.593	0.512	0.903	0.640	0.265	**0.592**
Line (50 LOC)	With-Header	**0.450** [0.398, 0.502]	0.580	**0.600**	**0.539**	**0.913**	**0.704**	**0.273**	0.572
AST Method	No-Header	0.320 [0.265, 0.369]	0.480	0.426	0.378	0.807	0.568	0.217	0.548
AST Method	With-Header	0.408 [0.346, 0.463]	**0.660**	0.594	0.491	0.900	0.584	0.236	0.544
Panel C: Lexical Sparse Baseline Tier (BM25)[†]									
Line (50 LOC)	No-Header	0.104 [0.070, 0.141]	**0.140**	0.113	0.106	0.337	0.128	0.071	0.136
Line (50 LOC)	With-Header	0.129 [0.094, 0.165]	**0.140**	0.144	0.126	0.405	0.168	0.092	0.180
AST Method	No-Header	**0.187** [0.145, 0.230]	0.080	**0.171**	**0.173**	**0.409**	**0.288**	**0.148**	**0.304**
AST Method	With-Header	0.170 [0.122, 0.221]	0.080	0.151	0.167	0.395	0.248	0.120	0.244
Pre-registered Random Baselines									
Random Selection	Full Corpus (798 Chunks)	0.019	—	—	—	—	—	—	—
Random Selection	Judged Pool Candidates[‡]	0.592	—	—	—	—	—	—	—

Note: 95% bootstrap confidence intervals across 25 JDs (10,000 resamples, seed 42) shown in brackets below NDCG@10. In each panel, **bold** denotes the best performing configuration, and underline denotes the second-best configuration. Linear relevance gain $\text{rel}/\log_2(i+1)$ is employed across all NDCG calculations.

[†] BM25 candidates were not included in the human judgment pool; unjudged items are treated as 0 (not relevant). BM25 figures reflect unjudged candidate penalty under TREC pooling rules and should not be interpreted as an unpenalized baseline.

[‡] Random selection within pool samples strictly from pre-judged items (rel $\in \{0, 1, 2\}$) and is non-comparable to open-retrieval systems facing unjudged candidates.

Tóm tắt Kết luận Thực nghiệm & Ý nghĩa Khoa học (Bảng 3):

- **Phương pháp Đạt Hiệu năng Toàn diện Cao nhất: Line With-Header** dẫn đầu trên mọi thước đo độ chính xác tại tầng Re-ranking (NDCG@10 = 0.499 [0.450, 0.543], NDCG@1 = 0.800, MRR@10 = 0.980, Context Precision CP@5 = 0.935).
- **Hiệu năng của AST: AST With-Header** xếp thứ hai (NDCG@10 = 0.457 [0.405, 0.509], NDCG@1 = 0.720, MRR@10 = 0.940). Nếu không có Header, AST bị tụt dốc nghiêm trọng xuống 0.345.
- **Vai trò Then chốt của Bộ Re-ranker:** Tầng Re-ranker Cross-Encoder (`bge-reranker-large`) nâng hiệu năng vượt bậc cho toàn bộ 4 cấu hình, đưa NDCG@10 từ 0.104–0.187 (BM25) và 0.320–0.450 (Dense BGE-M3) lên 0.345–0.499.
- **Kiểm toán Baseline Ngẫu nhiên:** Random selection trên toàn corpus (798 chunks) đạt NDCG@10 = 0.019; trên tập ứng viên pool đạt 0.592 (chỉ gồm các mục có nhãn người ≥ 0, không bị phạt unjudged).

3. Bảng 2 (Table II): Đặc trưng Hình thái Phân mảnh & Tính Toàn vẹn Cú pháp (Chunk Morphology)

Bảng 3: Chunk morphology, syntactic validity, and context header preservation across chunking strategies.

Strategy Group	Total (J/R)	Mean LOC ± SD	Tokens (Content)	Tokens (Header)	Clean Parse (%)	Intact Bnd (%)	Header (%)	Trunc > 512 (%)
Line (50 LOC Baseline)	434 (120/314)	41.0 ± 13.1	390.8 (388)	419.5 (420)	22.4%	44.0%	0.0%	124 (28.6%)
AST Pure (Methods/Funcs)	234 (133/101)	19.8 ± 16.7	211.3 (157)	254.5 (202)	97.9%	100.0%	100.0%	14 (6.0%)
AST Fallback (Line 50)	130 (20/110)	42.9 ± 13.0	367.0 (372)	394.5 (400)	20.0%	74.6%	0.0%	26 (20.0%)
AST Combined (Full Branch)	364 (153/211)	28.1 ± 19.0	266.9 (222)	304.5 (260)	70.1%	90.9%	64.3%	40 (11.0%)

Note: Evaluated over 40 GitHub repositories (189 source files). Tokenizer: `BAAI/bge-m3` (maximum context length 512). Chunk count breakdown: Total (Java / React-TS). Boundary Preservation reflects percentage of chunks not artificially sliced across syntactic statement boundaries. Clean Parse denotes syntactically valid code blocks parsable by tree-sitter without syntax errors. Data dynamically derived from `table_3_2_measured.json` and `chunk_corpus.parquet`.

Tóm tắt Kết luận Thực nghiệm & Ý nghĩa Khoa học (Bảng 2):

- **Tính Toàn vẹn Cú pháp:** AST thuần túy đạt tỷ lệ parse sạch gần như tuyệt đối (97.9% bởi Tree-sitter) và 100.0% nguyên vẹn ranh giới khối mã. Trong khi đó, phân mảnh theo dòng 50 LOC cắt ngang qua thân cú pháp ở 56.0% số chunk (chỉ 22.4% parse sạch, 44.0% giữ được ranh giới).
- **Bảo toàn Ngữ cảnh Cấu trúc:** AST lưu giữ 100.0% Context Header bao bọc (class, interface, signature). Phân mảnh theo dòng hoàn toàn đánh mất ngữ cảnh này (0.0%).
- **Bắt buộc Phải có Cơ chế Fallback:** Trong mã nguồn thực tế, các hàm dài vượt quá ngữ cảnh 512 token của mô hình embedding. AST bắt buộc phải kích hoạt fallback cửa sổ trượt (tỷ lệ fallback chung 35.7%, trong đó Java là 13.1%, React/TS là 52.1%). Việc các hàm dài bị xẻ nhỏ thành fallback dòng đã làm suy giảm ưu thế cú pháp của AST trên thực tế.